第九組

性別、婚姻與生育對薪資的影響

111208081經濟三袁湘芸,113701008應數一陳芊諭,111701009應數一鍾莘妮,113701020應數一柳淇悅,113701029應數一周宥閒,113701031應數一李明熹,113701033應數一鍾佳君

目錄

1 研究目的

2 研究方法

3 資料來源與變數設定

4 敘述統計量

5 回歸模型

6 研究結果

7 結論

8 附錄

9 參考資料

10 分工表

動機：男女生、結婚與否、有無撫養小孩都有可能會影響到薪資，但影響的效果也有可能因性別而有異。

研究目的

我們想透過回歸模型回答：

1.男女生平均薪資差異

2.結婚與否的平均薪資差異

3.婚姻溢酬對於男女生來說一樣嗎

4.有無小孩的平均薪資差異

5.有無小孩的平均薪資差異對男女生來說一樣嗎

研究方法

1.異質變異數檢測(Breusch-Pagan Test, White test)

- Breusch-Pagan Test :
  - 假設誤差項的變異數可能與解釋變數(x)相關。
  - 若BP統計量顯著，則拒絕同質變異數假設，需要考慮變異數可能異質。

2. VIF(Variance Inflation Factor)

- 衡量一個變數與其他變數之間共線性程度的指標。
- 當存在顯著的多重共線性問題時，所涉及的變數的VIF將非常大。
- VIF越高，存在多重共線性的可能性越大，需要進一步研究。當 VIF 高於 10 時，有顯著的多重共線性，需要進行校正。

3.OLS線性估計回歸

- 線性回歸基本概念:
  $Y=\beta_0+\beta_1X+\epsilon$ Y: 被解釋變數 X: 解釋變數
  β_0、β_1: 模型參數 ϵ: 誤差項
  多個解釋變數:$Y=\beta_0+\beta_1X_1+\beta_2X_2+...+\beta_kX_k+\epsilon$
- OLS特點: 假設數據成線性關係，誤差應具同質變異性。

4.Robust Standard Error(針對異質變異)

- 異質變異（Heteroskedasticity）指的是回歸模型的誤差項 ϵ 的變異數並非固定，而是隨著自變數 X 的值而改變。
- 當異質變異存在時，傳統 OLS 的標準誤差計算會不正確，能修正這種問題，給出更準確的參數標準誤差。

Matplotlib

1. 架構

- Backend Layer：實際繪圖核心
- Artist Layer：描述圖形組成與位置
- Scripting Layer：用戶簡化接口

2. 圖形結構與流程

- 圖形結構 (Plot Anatomy)：
  Figure：最外層容器
  Axes：核心繪圖區域，包含數據與標籤
- 工作流程
  導入模組→準備數據並創建圖形→繪圖→客製化並顯示

Statsmodels

Statsmodels 提供多種模型與方法，包括：線性模型、線性混合效應模型、方差分析、時間序列模型、廣義矩量法。

- 評估線性模型
  - 基於陣列：手動處理變數和矩陣操作
  - 基於公式：利用 Patsy 公式和 Pandas DataFrame 提供更直觀的接口

Pandas

1. 作圖
2. 讀取資料
3. 篩選資料

資料來源與變數設定

- 行政院主計總處（2012~2021）。100~109年人力運用調查【原始數據】取自中央研究院人文社會科學研究中心調查研究專題中心學術調查研究資料庫。
- 人力運用調查勞動力的短期變動
- 每年度調查樣本約2萬戶，5萬多人次
- 附圖為該調查的問卷樣式，約百餘題

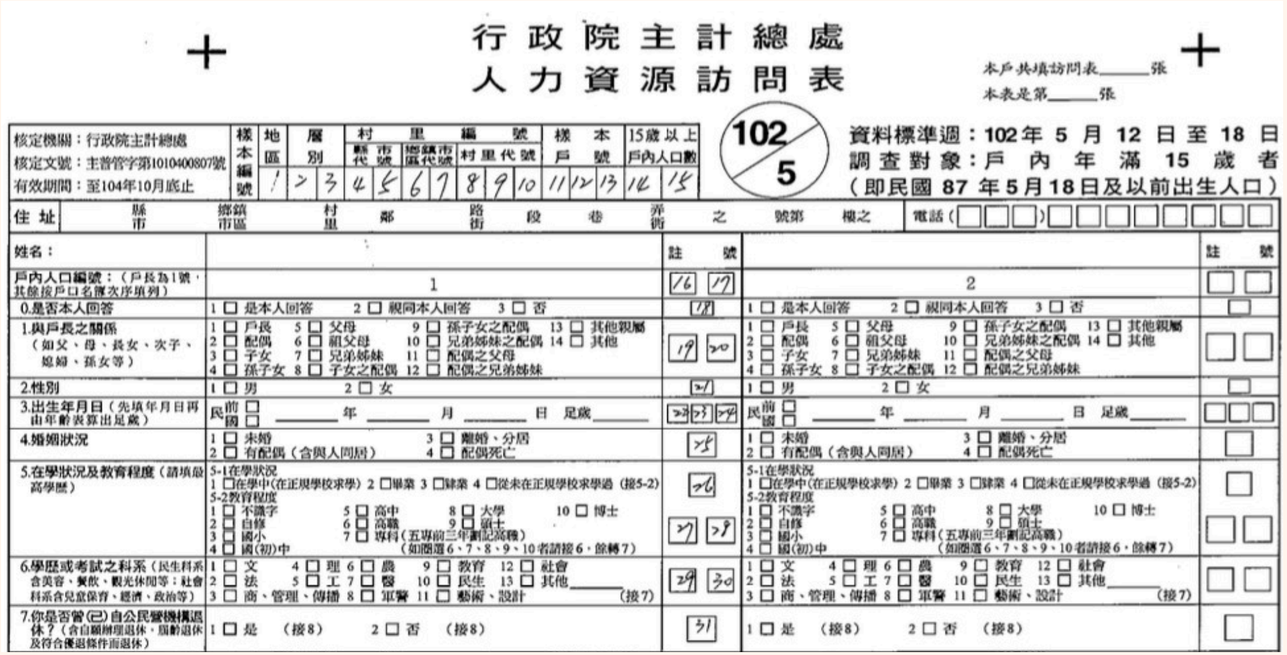

行政院主計總處
人力資源訪問表

本戶共填訪問表_____張
本表是第_____張

核定機關：行政院主計總處
核定文號：主普管字第1010400807號
有效期間：至104年10月底止

樣本編號	地區別	村里編號 縣市代號	鄉鎮市區代號	村里代號	樣本戶號	15歲以上戶內人口數
	1 2 3	4 5	6 7	8 9 10	11 12 13	14 15

102/5

資料標準週：102年5月12日至18日
調查對象：戶內年滿15歲者
（即民國87年5月18日及以前出生人口）

住址：縣市 鄉鎮市區 村里 鄰 路街 段 巷 弄 之 號 樓之 電話（□□□）□□□□□□□□

姓名：		註號		註號
戶內人口編號：（戶長為1號，其餘按戶口名簿次序填列）	1	16 17	2	□□
0.是否本人回答	1 □ 是本人回答 2 □ 親同本人回答 3 □ 否	18	1 □ 是本人回答 2 □ 親同本人回答 3 □ 否	□
1.與戶長之關係（如父、母、長女、次子、媳婦、孫女等）	1 □ 戶長 5 □ 父母 9 □ 孫子女之配偶 13 □ 其他親屬 2 □ 配偶 6 □ 祖父母 10 □ 兄弟姊妹之配偶 14 □ 其他 3 □ 子女 7 □ 兄弟姊妹 11 □ 配偶之父母 4 □ 孫子女 8 □ 子女之配偶 12 □ 配偶之兄弟姊妹	19 20	1 □ 戶長 5 □ 父母 9 □ 孫子女之配偶 13 □ 其他親屬 2 □ 配偶 6 □ 祖父母 10 □ 兄弟姊妹之配偶 14 □ 其他 3 □ 子女 7 □ 兄弟姊妹 11 □ 配偶之父母 4 □ 孫子女 8 □ 子女之配偶 12 □ 配偶之兄弟姊妹	□□
2.性別	1 □ 男 2 □ 女	21	1 □ 男 2 □ 女	□
3.出生年月日（先填年月日再由年齡表算出足歲）	民國前□ 民國□ _____年 _____月 _____日 足歲_____	22 23 24	民國前□ 民國□ _____年 _____月 _____日 足歲_____	□□□
4.婚姻狀況	1 □ 未婚 3 □ 離婚、分居 2 □ 有配偶（含與人同居） 4 □ 配偶死亡	25	1 □ 未婚 3 □ 離婚、分居 2 □ 有配偶（含與人同居） 4 □ 配偶死亡	□
5.在學狀況及教育程度（請填最高學歷）	5-1在學狀況 1 □在學中(在正規學校求學) 2 □畢業 3 □肄業 4 □從未在正規學校求學過（接5-2） 5-2教育程度 1 □ 不識字 5 □ 高中 8 □ 大學 10 □ 博士 2 □ 自修 6 □ 高職 9 □ 碩士 3 □ 國小 7 □ 專科（五專前三年劃記高職） 4 □ 國(初)中 （如圈選6、7、8、9、10者請接6，餘轉7）	26 27 28	5-1在學狀況 1 □在學中(在正規學校求學) 2 □畢業 3 □肄業 4 □從未在正規學校求學過（接5-2） 5-2教育程度 1 □ 不識字 5 □ 高中 8 □ 大學 10 □ 博士 2 □ 自修 6 □ 高職 9 □ 碩士 3 □ 國小 7 □ 專科（五專前三年劃記高職） 4 □ 國(初)中 （如圈選6、7、8、9、10者請接6，餘轉7）	□ □□
6.學歷或考試之科系（民生科系含美容、餐飲、觀光休閒等；社會科系含兒童保育、經濟、政治等）	1 □ 文 4 □ 理 6 □ 農 9 □ 教育 12 □ 社會 2 □ 法 5 □ 工 7 □ 醫 10 □ 民生 13 □ 其他_____ 3 □ 商、管理、傳播 8 □ 軍警 11 □ 藝術、設計 （接7）	29 30	1 □ 文 4 □ 理 6 □ 農 9 □ 教育 12 □ 社會 2 □ 法 5 □ 工 7 □ 醫 10 □ 民生 13 □ 其他_____ 3 □ 商、管理、傳播 8 □ 軍警 11 □ 藝術、設計 （接7）	□□
7.你是否曾(已)自公民營機構退休？（含自願提早退休、屆齡退休及符合優退條件而退休）	1 □ 是 （接8） 2 □ 否 （接8）	31	1 □ 是 （接8） 2 □ 否 （接8）	□

資料來源與變數設定

- 我們從50多萬筆資料中選取符合
  - 已婚或未婚(排出喪偶、離婚)
  - 全職工作者
- 篩選後實際研究資料共241908樣本
- 接著從100多個變數中選取右列變數
  - wage為被解釋變數
  - 其餘變數為解釋變數

變數名稱	英文縮寫	附註
月薪	wage	月經常性薪資
年齡	age	
性別	gender	男性：0 / 女性：1
婚姻狀況	marriage	未婚：0 / 已婚：1
教育狀況	edu	1.不識字2.自修3.國小4.國中 5.高中6.高職7.專科8.大學 9.碩士10.博士
工作類型	work type	1.雇主 2.自營作業者 3.受政府僱用者 4.受私人僱用者
小孩數量	children	只計算未滿18歲子女
是否為全職工作者	fulltime	
週工時	work time	
對數薪資	lwage	由月薪資取log
受教育年數	yedu	由教育程度轉換成年分
是否有小孩	have children	由小孩數量轉換而來 沒小孩：0 / 有小孩：1

敘述統計量

性別、婚姻、生育的薪資情況

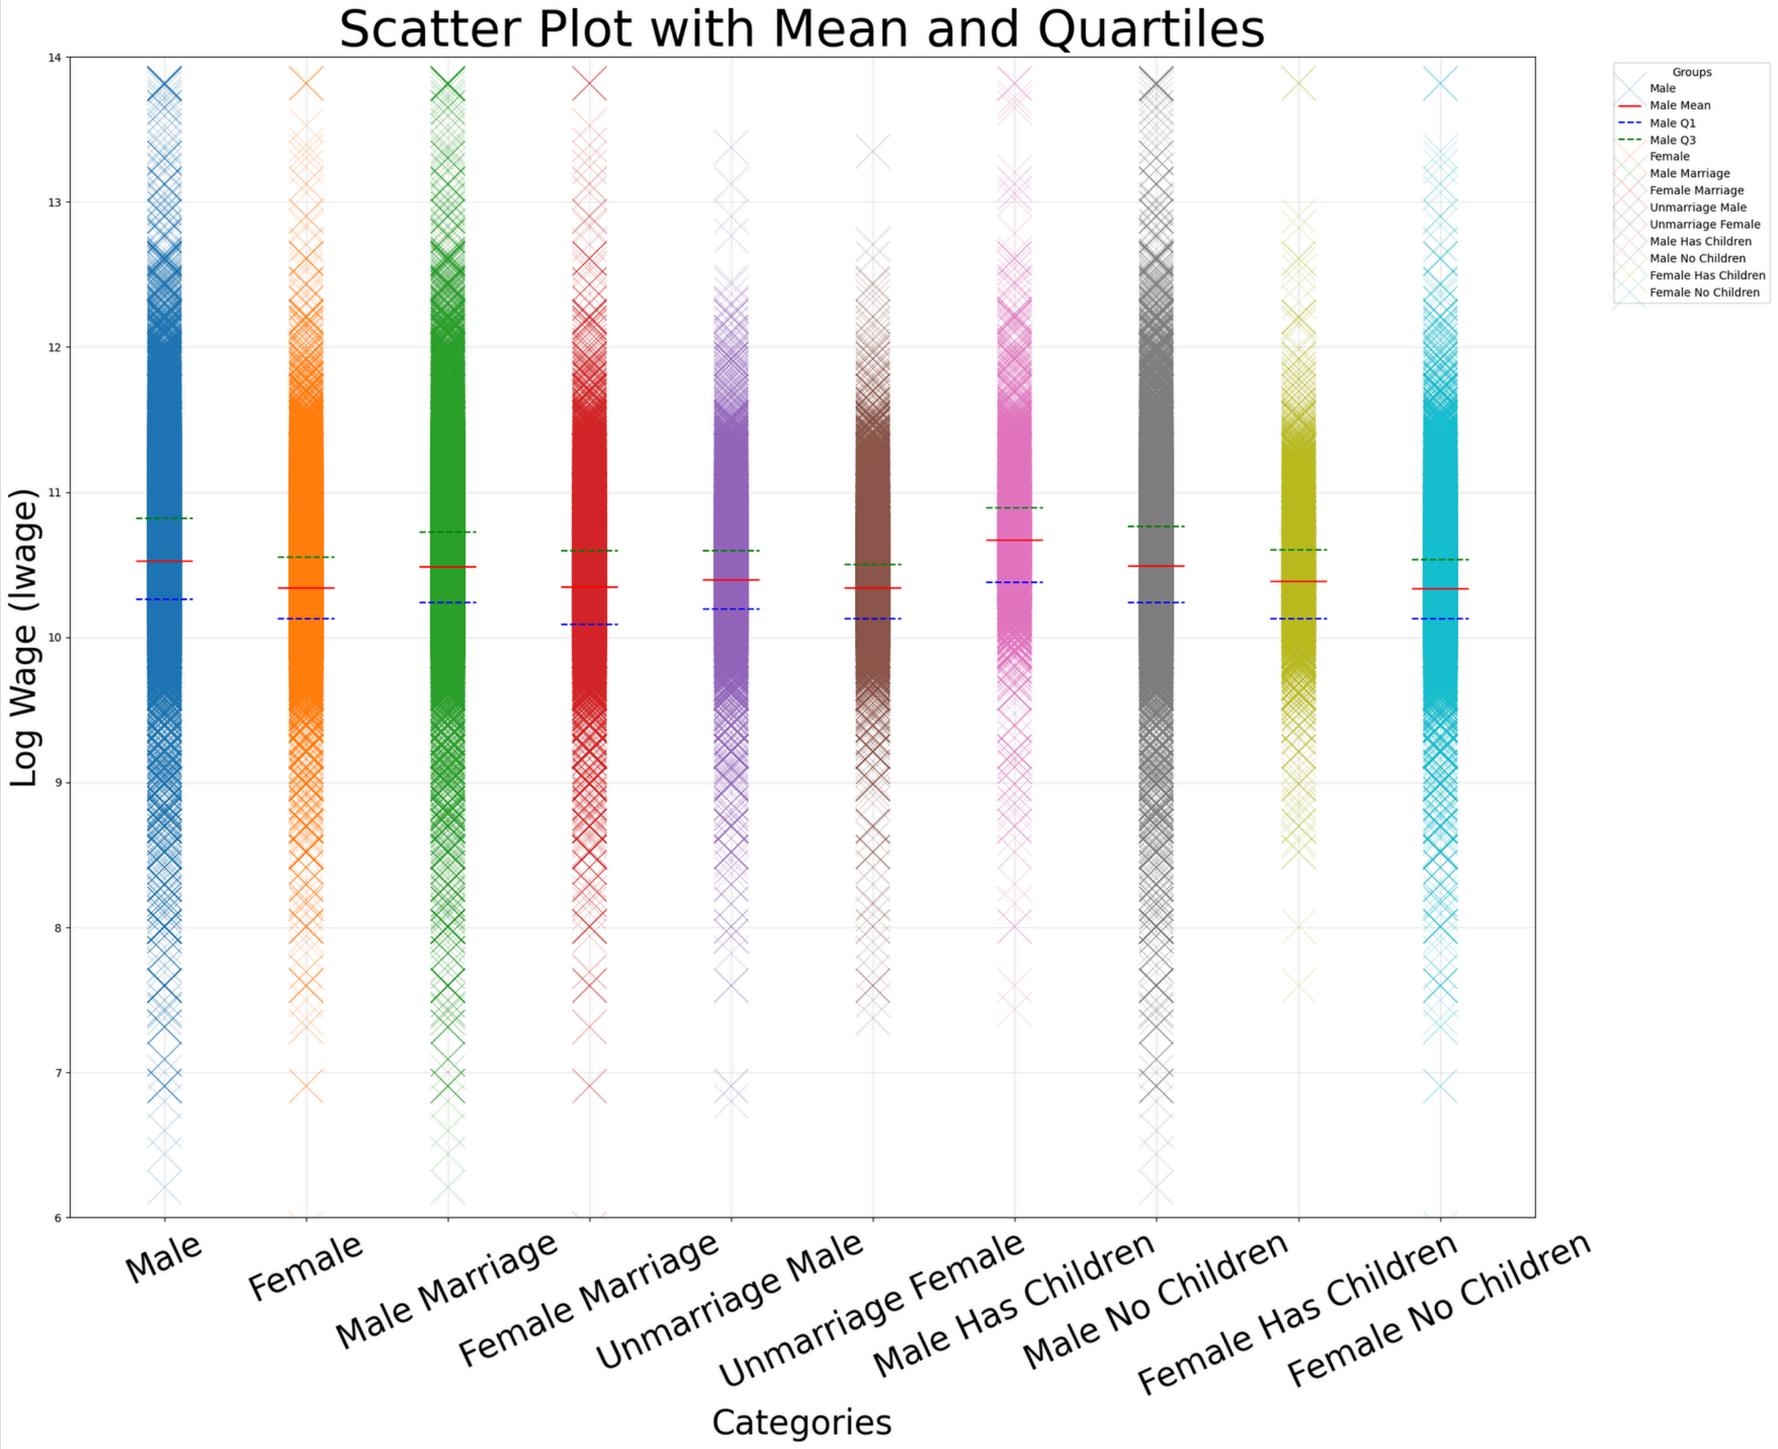

男性與女性薪資對比

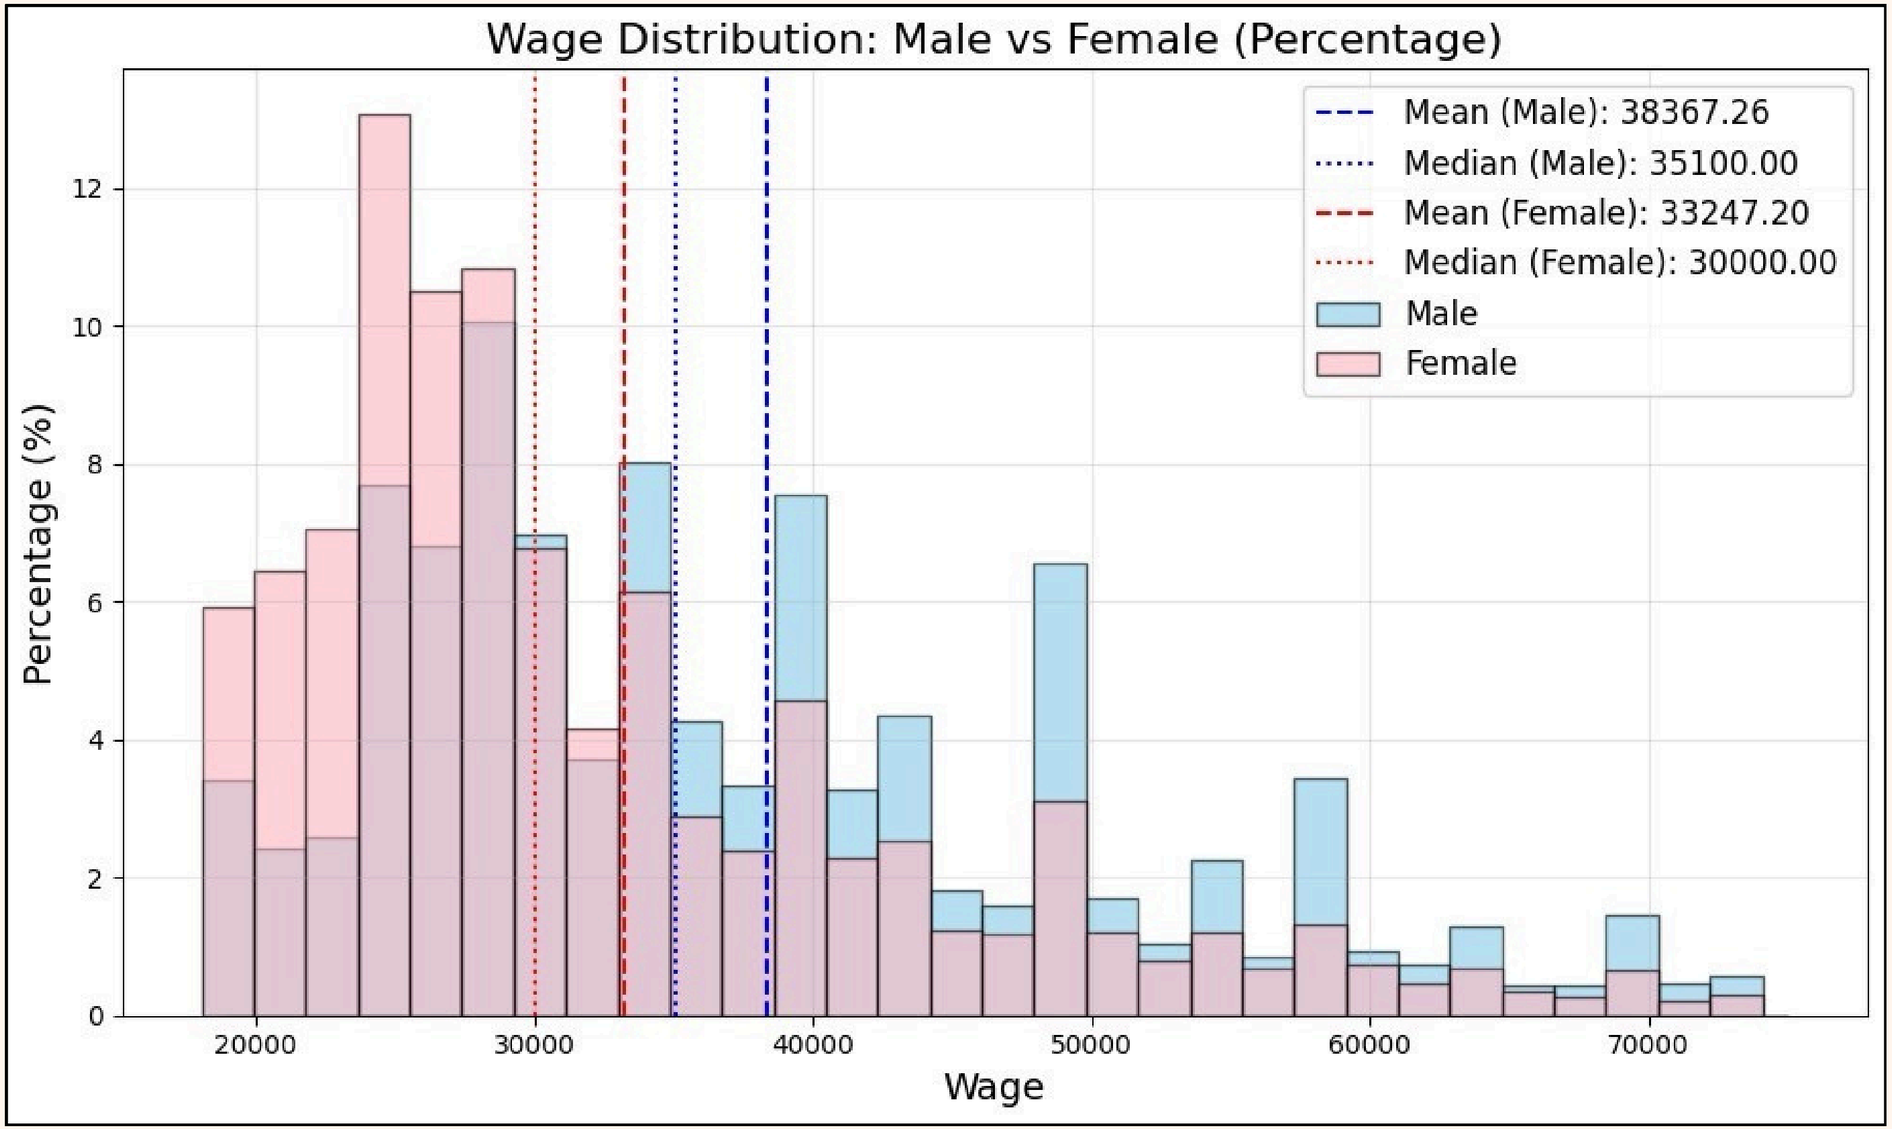
Wage Distribution: Male vs Female (Percentage)
Mean (Male): 38367.26
Median (Male): 35100.00
Mean (Female): 33247.20
Median (Female): 30000.00
Male
Female
Percentage (%)
0
2
4
6
8
10
12
20000
30000
40000
50000
60000
70000
Wage

已婚與未婚薪資對比

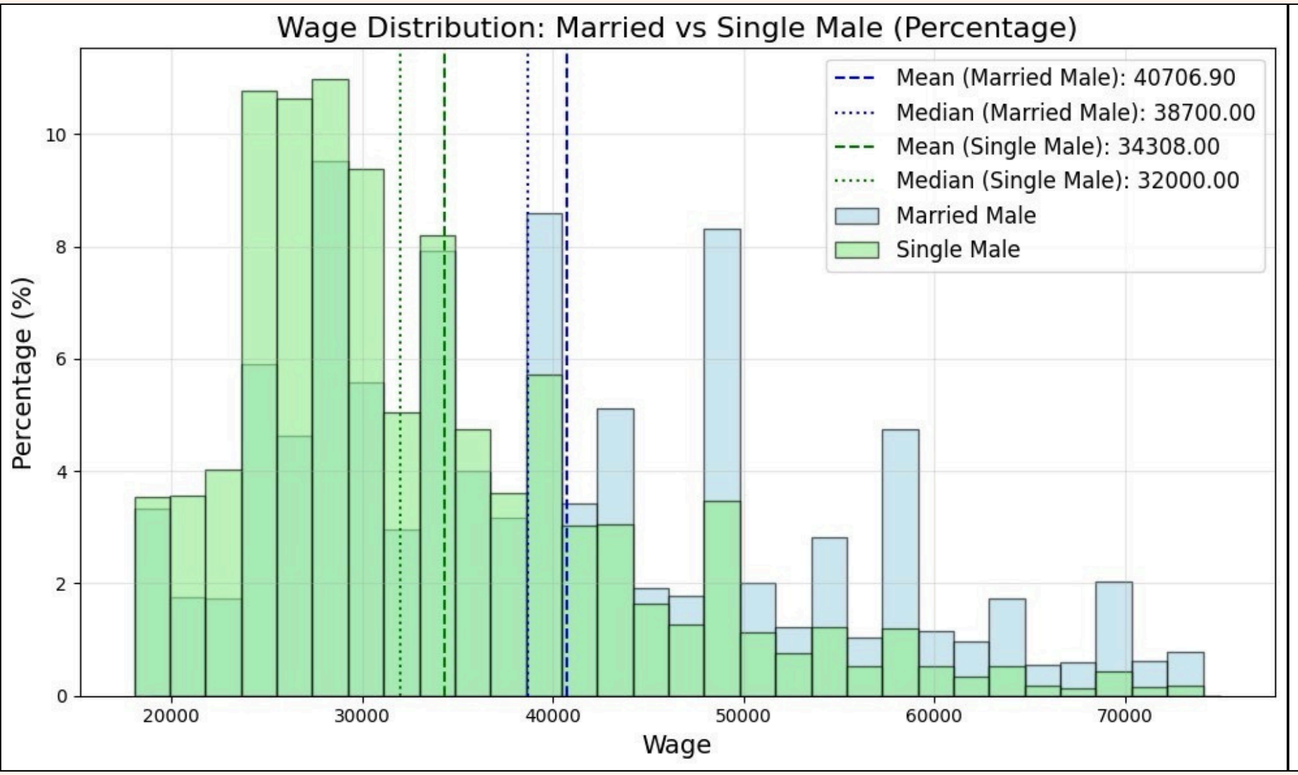
Wage Distribution: Married vs Single Male (Percentage)
Mean (Married Male): 40706.90
Median (Married Male): 38700.00
Mean (Single Male): 34308.00
Median (Single Male): 32000.00
Married Male
Single Male
Percentage (%)
Wage
0
2
4
6
8
10
20000
30000
40000
50000
60000
70000

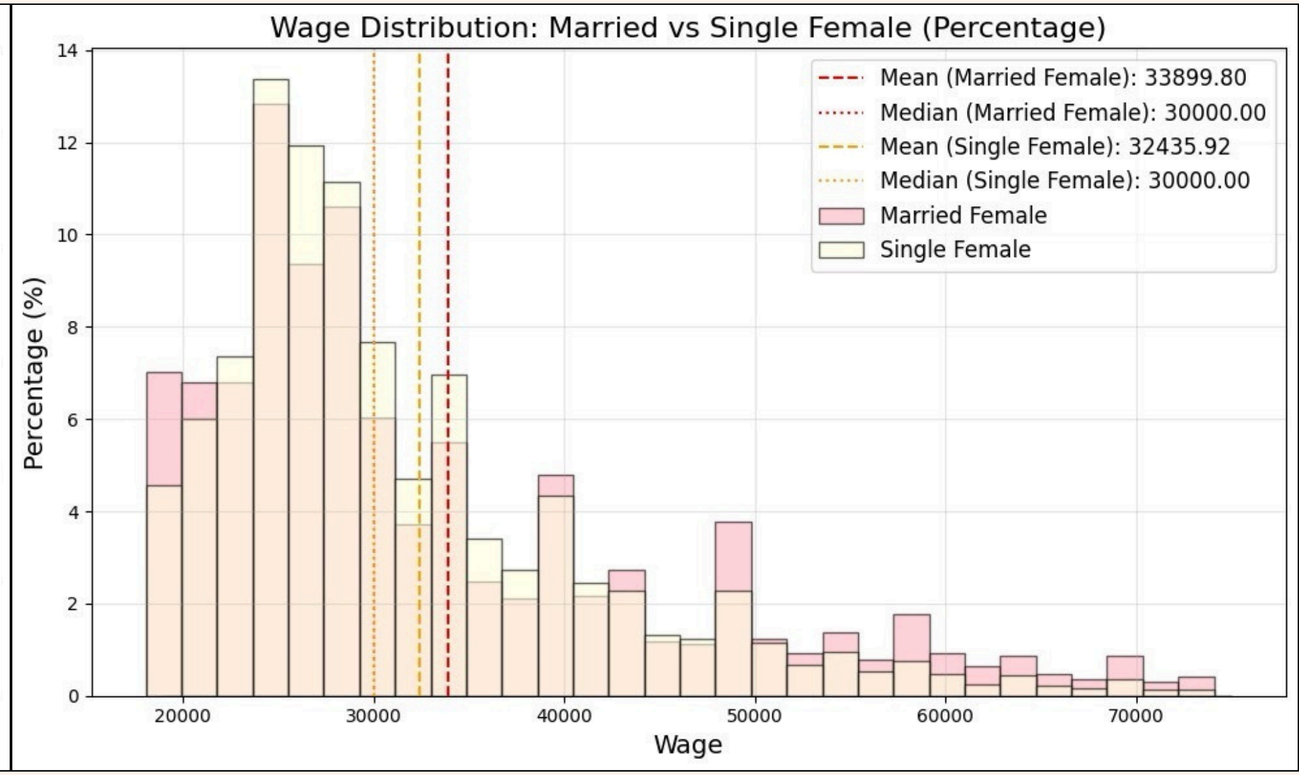
Wage Distribution: Married vs Single Female (Percentage)
Mean (Married Female): 33899.80
Median (Married Female): 30000.00
Mean (Single Female): 32435.92
Median (Single Female): 30000.00
Married Female
Single Female
Percentage (%)
Wage
0
2
4
6
8
10
12
14
20000
30000
40000
50000
60000
70000

有無小孩薪資對比

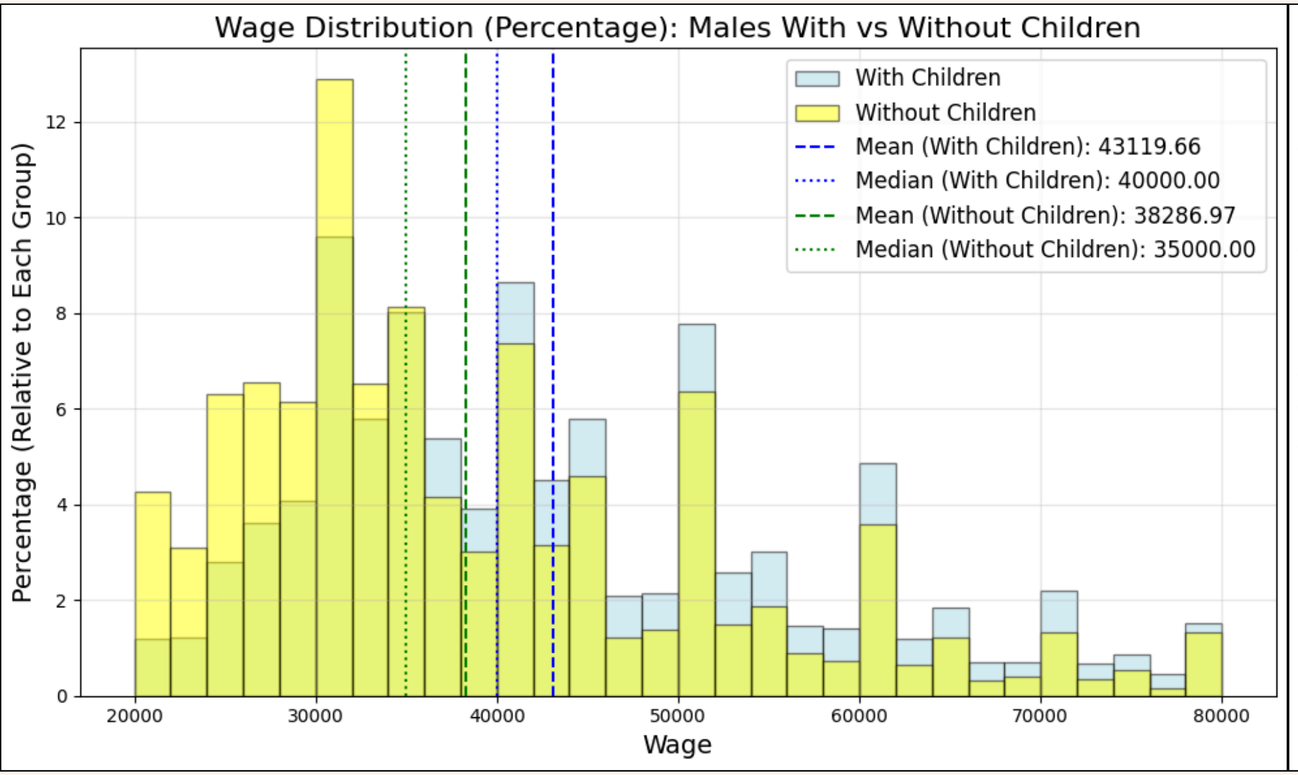
Wage Distribution (Percentage): Males With vs Without Children
With Children
Without Children
Mean (With Children): 43119.66
Median (With Children): 40000.00
Mean (Without Children): 38286.97
Median (Without Children): 35000.00
Percentage (Relative to Each Group)
Wage
0
2
4
6
8
10
12
20000
30000
40000
50000
60000
70000
80000

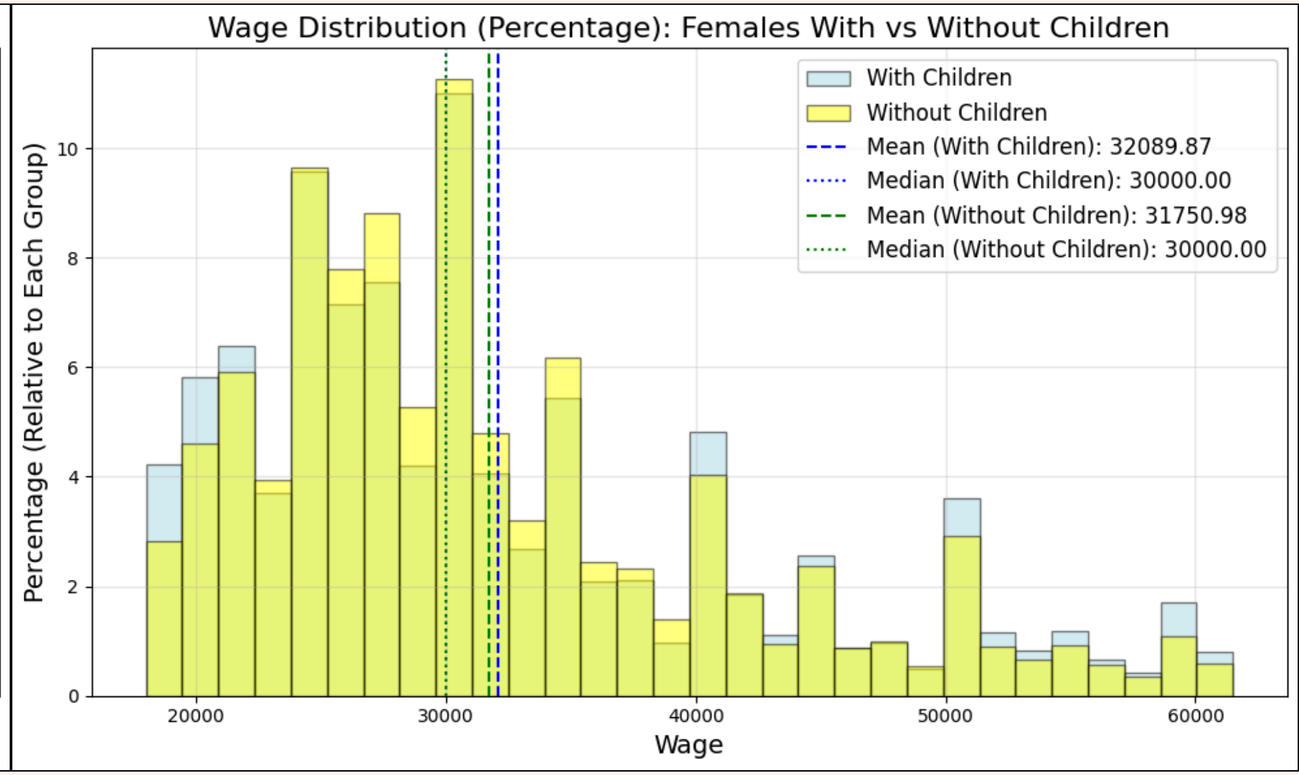
Wage Distribution (Percentage): Females With vs Without Children
With Children
Without Children
Mean (With Children): 32089.87
Median (With Children): 30000.00
Mean (Without Children): 31750.98
Median (Without Children): 30000.00
Percentage (Relative to Each Group)
Wage
0
2
4
6
8
10
20000
30000
40000
50000
60000

迴歸模型

$$\log(\text{wage}) = \beta_0 + \beta_1\text{gender} + \beta_2\text{marriage} + \beta_3\text{gender} \times \text{marriage} + \beta_4\text{have children} + \epsilon$$

$$\begin{aligned}\log(\text{wage}) = {} & \beta_0 + \beta_1\text{gender} + \beta_2\text{marriage} + \beta_3\text{gender} \times \text{marriage} + \beta_4\text{have children} \\ & + \beta_5\text{gender} \times \text{have children} + \epsilon\end{aligned}$$

$$\begin{aligned}\log(\text{wage}) = {} & \beta_0 + \beta_1\text{gender} + \beta_2\text{marriage} + \beta_3\text{gender} \times \text{marriage} + \beta_4\text{have children} \\ & + \beta_5\text{gender} \times \text{have children} + \gamma_1\text{age} + \gamma_2\text{private} + \gamma_3\text{public} \\ & + \gamma_4\text{self employed} + \gamma_5\text{work time} + \gamma_6\text{years of edu} + \epsilon\end{aligned}$$

	No children		have children	
	Unmarried	Married	Unmarried	Married
Male	β_0	$\beta_0 + \beta_2$	$\beta_0 + \beta_4$	$\beta_0 + \beta_2 + \beta_4$
Female	$\beta_0 + \beta_1$	$\beta_0 + \beta_1 + \beta_2 + \beta_3$	$\beta_0 + \beta_1 + \beta_4$	$\beta_0 + \beta_1 + \beta_2 + \beta_3 + \beta_4 + \beta_5$

- 此表建立在Model3的設定下，將控制項(age,work time,...)控制住不變
- 因為未婚生子佔比僅有千分之三，因此不特別討論。

我們想透過回歸模型回答：

1.男女生平均薪資差異　β1

2.結婚與否的平均薪資差異　男性: β2 女性: β2+β3

3.婚姻溢酬對於男女生來說一樣嗎　取決於β3 是否為0

4.有無小孩的平均薪資差異　男性: β4　女性: β4+β5

5.有無小孩的平均薪資差異對男女生來說一樣嗎　取決於β5 是否為0

$$X \Rightarrow \log X$$

$$\frac{dlogX}{dX} = \frac{1}{X}$$

$$\Delta \log X \cdot 100\% \approx \Delta X / X = \%\Delta X$$

研究結果

在控制年齡、工作時數、受教育年數與工作類別後

1.未婚女性薪資比未婚男性低10.6%

2.無小孩已婚女性薪資比已婚男性低21.2%

3.婚姻溢酬對男女性的效果並不相同，

男性結婚使薪水上升14.3%但女性僅上升3.7%

4.有小孩已婚女性薪資比已婚男性低28.4%

5.扶養小孩對男女性薪資效果並不相同

	Dependent variable: log(wage)		
	Model (1)	Model (2)	Model (3)
const	10.393***	10.393***	9.294***
	(0.002)	(0.002)	(0.012)
gender	-0.056***	-0.056***	-0.106***
	(0.002)	(0.002)	(0.002)
marriage	0.174***	0.164***	0.143***
	(0.002)	(0.003)	(0.003)
gender × marriage	-0.214***	-0.175***	-0.106***
	(0.003)	(0.004)	(0.004)
have children	0.085***	0.122***	0.085***
	(0.003)	(0.003)	(0.003)
gender× have children		-0.090***	-0.072***
		(0.005)	(0.004)
age			0.007***
			(0.000)
private			-0.391***
			(0.005)
public			-0.174***
			(0.006)
self employed			-0.555***
			(0.006)
work time			0.010***
			(0.000)
years of edu			0.060***
			(0.000)
Observations	241908	241908	241908
R^2	0.066	0.067	0.327
Adjusted R^2	0.066	0.067	0.327
Residual Std. Error	0.447 (df=241903)	0.447 (df=241902)	0.380 (df=241896)
F Statistic	4212.927*** (df=4; 241903)	3656.287*** (df=5; 241902)	9304.459*** (df=11; 241896)
Note:	[1] Standard Errors are heteroscedasticity robust (HC1) [2]*p<0.1; **p<0.05; ***p<0.01		

異質變異數檢測

異質變異數檢測_BP test

H0:同質變異數

H1:異質變異數

拒絕H0

BPtest有兩種測法 LM統計量和F統計量

```
bp_test = sms.het_breuschpagan(model_3.resid, model_3.model.exog)

print(bp_test)
print("Breusch-Pagan Test results:")
print("LM Statistic:",bp_test[0])
print("p-value:" ,bp_test[1])    # LM statistic
```

```
(17206.639766636486, 0.0, 1683.9390447625187, 0.0)
Breusch-Pagan Test results:
LM Statistic: 17206.639766636486
p-value: 0.0
```

GVIF共線性檢測

```
model_3 <- lm(lwage ~ gender+marriage+gender_marriage+have_children+gender_have_children+age+yedu+work_time+self_employed+public+private, data = dt)
robust_se_3<- sqrt(diag(vcovHC(model_3, type = "HC1")))
coeftest(model_3, vcov = vcovHC(model_3, type = "HC1"))

vif_values <- vif(model_3)
print(vif_values)
```

```
        gender          marriage    gender_marriage      have_children gender_have_children               age              yedu         work_time
      2.580995          2.884157          4.258897           2.426211             3.362559          2.140642          1.353013          1.042474
self_employed            public           private
      3.690724          3.077396          5.245571
```

- 以R語言呈GVIF檢測
- VIF>10為高度共線性，會造成估計偏誤

結論

即使性別平等觀念有進步趨勢，但本研究顯示是已婚、未婚、有無小孩，
女性薪資均低於男性薪資，且生育與婚姻會擴大男女性薪資差距。

未來展望：政府與企業應打造性別友善的職場以消弭男女薪資差距，
也有助於解決低生育率的社會困境。

研究限制：

1.非Panel Data => 無法控制人格特質動機等個人固定效應，且無法直接觀測到婚姻、生育對單一個體的效果。

2.反向因果關係: 高薪資可能使家庭更有動機結婚、生育。需要有更嚴謹的因果推論方法處理。

附錄

散點圖繪製程式碼

```python
import pandas as pd
import matplotlib.pyplot as plt
import numpy as np

# 讀取 CSV 檔案
file_path = 'Human_Capital_tidy_data.csv'    # 替換為你的檔案名稱
data = pd.read_csv(file_path)

# 定義組別與對應的資料篩選
categories = [
        ('Male', data[data['gender'] == 0]['lwage']),
        ('Female', data[data['gender'] == 1]['lwage']),
        ('Male Marriage', data[data['gender_marriage'] == 0]['lwage']),
        ('Female Marriage', data[data['gender_marriage'] == 1]['lwage']),
        ('Unmarriage Male', data[(data['gender'] == 0) & (data['marriage'] == 0)]['lwage']),
        ('Unmarriage Female', data[(data['gender'] == 1) & (data['marriage'] == 0)]['lwage']),
        ('Male Has Children', data[(data['gender'] == 0) & (data['children'] == 1)]['lwage']),
        ('Male No Children', data[(data['gender'] == 0) & (data['children'] == 0)]['lwage']),
        ('Female Has Children', data[(data['gender'] == 1) & (data['children'] == 1)]['lwage']),
        ('Female No Children', data[(data['gender'] == 1) & (data['children'] == 0)]['lwage']),
]

# 準備繪製資料
x_labels = [cat[0] for cat in categories]    # X 軸類別標籤
y_values = [cat[1] for cat in categories]    # 各組別的 Y 軸資料
```

```python
# 繪製散點圖
plt.figure(figsize=(26, 18))
for i, y in enumerate(y_values):
        x = [x_labels[i]] * len(y)    # 每組的 X 軸位置
        plt.plot(x, y, 'x', alpha=0.6, markersize=30, markeredgewidth=0.3, label=x_labels[i])    # 調整 "X" 的大小和粗細

        # 計算統計量
        mean_value = np.mean(y)
        q1 = np.percentile(y, 25)    # 第一四分位數
        q3 = np.percentile(y, 75)    # 第三四分位數

        # 繪製水平線（標示平均數與四分位數）
        plt.hlines(mean_value, i - 0.2, i + 0.2, colors='red', label=f'{x_labels[i]} Mean' if i == 0 else "")
        plt.hlines(q1, i - 0.2, i + 0.2, colors='blue', linestyle='dashed', label=f'{x_labels[i]} Q1' if i == 0 else "")
        plt.hlines(q3, i - 0.2, i + 0.2, colors='green', linestyle='dashed', label=f'{x_labels[i]} Q3' if i == 0 else "")

plt.tight_layout()
# 設置圖表
plt.title('Scatter Plot with Mean and Quartiles', fontsize=45)
plt.xlabel('Categories', fontsize=30)
plt.ylabel('Log Wage (lwage)', fontsize=30)
plt.xticks(rotation=25, fontsize=30)
plt.ylim(6, 14)    # 調整縱座標範圍，例如 [6, 14]
plt.grid(alpha=0.3)
plt.legend(title='Groups', bbox_to_anchor=(1.05, 1), loc='upper left')
plt.tight_layout()

# 顯示圖表
plt.show()
```

附錄

直方圖繪製程式碼(男女薪資對比)

```python
import pandas as pd
import matplotlib.pyplot as plt
import numpy as np

# 載入資料（請將 'Human_Capital_tidy_data.csv' 替換為你的檔案名稱）
data = pd.read_csv('Human_Capital_tidy_data.csv')

# 計算薪資的上下百分位數（排除極端值）
lower_bound = data['wage'].quantile(0.05)   # 第 5 百分位
upper_bound = data['wage'].quantile(0.95)   # 第 95 百分位

# 篩選掉極端值
filtered_data = data[(data['wage'] >= lower_bound) & (data['wage'] <= upper_bound)]

# 篩選男生資料（gender == 0）
male_data = filtered_data[filtered_data['gender'] == 0]['wage']

# 篩選女生資料（gender == 1）
female_data = filtered_data[filtered_data['gender'] == 1]['wage']

# 設置圖表大小
plt.figure(figsize=(12, 7))

# 計算男生的百分比
plt.hist(
        male_data, bins=30, alpha=0.5, label='Male',
        color='skyblue', edgecolor='black',
        weights=np.ones(len(male_data)) / len(male_data) * 100   # 個別比例
)

# 計算女生的百分比
plt.hist(
        female_data, bins=30, alpha=0.5, label='Female',
        color='lightpink', edgecolor='black',
        weights=np.ones(len(female_data)) / len(female_data) * 100   # 個別比例
)
```

```python
# 計算統計量（男生）
mean_male = male_data.mean()
median_male = male_data.median()

# 計算統計量（女生）
mean_female = female_data.mean()
median_female = female_data.median()

# 繪製統計量的垂直線（男生）
plt.axvline(mean_male, color='blue', linestyle='dashed', linewidth=1.5, label=f'Mean (Male): {mean_male:.2f}')
plt.axvline(median_male, color='blue', linestyle='dotted', linewidth=1.5, label=f'Median (Male): {median_male:.2f}')

# 繪製統計量的垂直線（女生）
plt.axvline(mean_female, color='red', linestyle='dashed', linewidth=1.5, label=f'Mean (Female): {mean_female:.2f}')
plt.axvline(median_female, color='red', linestyle='dotted', linewidth=1.5, label=f'Median (Female): {median_female:.2f}')

# 設置標題和標籤
plt.title('Wage Distribution (Percentage): Male vs Female', fontsize=16)
plt.xlabel('Wage', fontsize=14)
plt.ylabel('Percentage (Relative to Each Group)', fontsize=14)
plt.legend(fontsize=12)
plt.grid(alpha=0.3)

# 顯示圖表
plt.tight_layout()
plt.show()
```

附錄

- 資料處理與回歸模型程式碼

Google Colab
co google.com

- 迴歸式八宮格參數表

Tables Generator LaTeX HTML Text Markdown MediaWiki

File Edit Table Column Row Cell Help

Default table style

		No children		have children	
		Unmarried	Married	Unmarried	Married
	Male	β_0	$\beta_0+\beta_2$	$\beta_0+\beta_4$	$\beta_0+\beta_2+\beta_4$
	Female	$\beta_0+\beta_1$	$\beta_0+\beta_1+\beta_2+\beta_3$	$\beta_0+\beta_1+\beta_4$	$\beta_0+\beta_1+\beta_2+\beta_3+\beta_4+\beta_5$

Generate

Result (click "Generate" to refresh)

- ChatGPT

參考資料

- (Statsmodels套件) Seabold, Skipper, and Josef Perktold. ‘‘statsmodels: Econometric and statistical modeling with python.’’ Proceedings of the 9th Python in Science Conference. 2010.
- (NumPy套件) Harris, C.R., Millman, K.J., van der Walt, S.J. et al. Array programming with NumPy. Nature 585, 357–362 (2020). DOI: 10.1038/s41586-020-2649-2.
- (Pandas套件) The pandas development team. (2024). pandas-dev/pandas: Pandas (v2.2.3). Zenodo.
- (Matplotlib套件) J. D. Hunter, "Matplotlib: A 2D Graphics Environment", Computing in Science & Engineering, vol. 9, no. 3, pp. 90-95, 2007.
- (Stargazer套件) https://pypi.org/project/stargazer/
- Wooldridge (2020) Introductory Econometrics: A Modern Approach, the 7th edition
- 行政院主計總處（2012-2021）。100年-109年人力運用調查【原始數據】取自中央研究院人文社會科學研究中心調查研究專題中心學術調查研究資料庫。https://srda.sinica.edu.tw/plan/?idx=SRDA.GS002

分工表

袁湘芸	組長、資料處理、建立回歸模型與檢測、報告
周宥閒	視覺化圖表、敘述統計量、參與討論、報告
鐘莘妮	視覺化圖表、敘述統計量、參與討論、報告
柳淇悅	研究目的、研究方法、參與討論、報告
鍾佳君	研究方法、參與討論、報告
李明熹	資料來源與變數設定、參與討論、報告
陳芊諭	研究方法、參與討論、報告